

OAT 1 – Compreensão e Baseline

Autor: Joaqson Rodrigues Miranda
Lucas Santos Oliveira
Manoel Souza Santos
Monique Prado Pereira Gomes
Raian Rocha Santos

Agenda

Apresentar o módulo fundacional de análise preditiva da MecâniQA: da limpeza dos dados até os modelos baseline.

1. Contexto:

O problema de negócio e os dados do produto

2. Limpeza:

Tratamento de dados ausentes, inválidos e outliers

3. EDA:

EDA: Tendência, Sazonalidade e Ruído

4. Baseline

Modelos Baseline: Naive e Médias Móveis

5. Resultados

Resultados e próximos passos

Contexto do Negócio




- Clientes: donos de oficinas e auto centers de Feira de Santana e região;
- Problema: picos inesperados de manutenção preventiva geram falta de peças em alguns dias e ociosidade dos mecânicos em outros;
- Missão da equipe: construir o módulo fundacional de análise preditiva a partir do histórico de Trocas de Óleo e Manutenções de Motor;
- Objetivo desta sprint: entender a série temporal do negócio e criar o primeiro motor de previsão "ingênuo" (Baseline).

Qualidade dos Dados: Achados




- **Dados ausentes:** 9 dias sem registro — 6 dias em Trocas de Óleo (10-15/abr/2024) e 3 dias em Manutenção de Motor (27-29/out/2024)
- **Valores inválidos:** 5 contagens negativas em Manutenção de Motor (set/2024) — erro de lançamento no sistema
- **Outliers:** 150 trocas de óleo em 15/02/2024 e 85 manutenções de motor em 19/07/2024 — muito acima do padrão ($Z\text{-score} > 3$)
- **Estratégia adotada:** interpolação temporal, que preserva a tendência e a sazonalidade local (mais realista que o forward fill)

Tratamento de Outliers



Outlier de 150 trocas em 15/02/2024 (erro de digitação) detectado por Z-score e normalizado por interpolação temporal.

Série Temporal e Tendência




A média móvel de 30 dias suaviza as oscilações diárias e facilita a visualização da tendência ao longo do período.

Sazonalidade Semanal

Padrão semanal identificado:


A demanda é menor de segunda a quinta e aumenta significativamente a partir de sexta-feira.

O comportamento ocorre tanto nas Trocas de Óleo quanto nas Manutenções de Motor, indicando uma sazonalidade semanal bem definida.



Maior demanda: sexta-feira, sábado e domingo.

Decomposição da Série




Modelo aditivo (period=7): sazonalidade semanal constante, tendência de crescimento gradual e ruído residual.

Baseline: Metodologia



- **Modelo Naive:** a previsão de amanhã é exatamente igual à demanda de hoje — o piso mais simples possível.
- **Médias Móveis (7 e 30 dias):** a previsão é a média das últimas manutenções — a janela de 7 dias captura o ciclo semanal, a de 30 dias suaviza para a tendência.
- **Por que precisamos disso:** todo modelo futuro de Machine Learning da MecâniQA precisa provar que supera esse piso de comparação.
- **Avaliação:** comparamos histórico real x previsões nos últimos 30 dias, usando MAE e RMSE.

Real x Previsões Baseline



Nos últimos 30 dias, a Média Móvel de 7 dias teve o menor erro entre os baselines (MAE 6,66 x 10,50 do Naive).

Considerações finais



- O dataset da MecâniQA (2024-2025) tinha dados ausentes, valores negativos inválidos e outliers — todos tratados por interpolação temporal.
- A decomposição evidenciou tendência ao longo do período, sazonalidade semanal clara e variações residuais.
- Os modelos Naive e Médias Móveis (7 e 30 dias) foram implementados e avaliados — a Média Móvel de 7 dias teve o melhor desempenho (menor MAE/RMSE).
- **Próximos passos:** incorporar variáveis exógenas (feriados, clima) e testar modelos mais robustos (SARIMA, Holt-Winters, XGBoost) contra este piso de comparação.

Referências



- **Dataset:** MecâniQA Dataset — histórico diário de Trocas de Óleo e Manutenção de Motor (2024-2025), fornecido pelo programa
- **Documentação:** pandas.pydata.org — manipulação e indexação de séries temporais
- statsmodels.org — `seasonal_decompose` (decomposição em tendência, sazonalidade e ruído)
- **Repositório da equipe:** github.com/jorodrigues0/mecaniQA-fortaleza