

Baseline e Métricas de Avaliação

Autores: Joaqson Rodrigues Miranda
Lucas Santos Oliveira
Manoel Souza Santos
Monique Prado Pereira Gomes
Raian Rocha Santos

Agenda

O objetivo desta apresentação é avaliar modelos baseline para previsão da demanda de manutenção da MecâniQA, utilizando atributos temporais, validação cruzada e métricas de desempenho.

1. Cenário e objetivo da Sprint:

Contexto da MecâniQA e desafio de previsão.

2. Dataset e preparação temporal:

Série temporal e organização dos dados.

3. Feature Engineering Temporal:

Lags e janelas rolantes.

4. Validação Temporal e Boas Práticas:

TimeSeriesSplit, Data Leakage e Overfitting.

5. Avaliação e Resultados:

Baselines, MAE, RMSE e MAPE.

Cenário e objetivo da Sprint



Picos inesperados de demanda impactam o estoque de peças e a utilização da equipe.

- **Problema:** Demanda variável por manutenção preventiva.
- **Impacto:** Falta de peças em alguns dias e ociosidade dos mecânicos em outros.
- **Objetivo:** Evoluir e avaliar os modelos baseline para medir o quão próximas as previsões estão da demanda real.



Dataset e preparação temporal

- Base utilizada:
 - Série temporal diária — 2024 a 2025.
 - Variáveis analisadas: Trocas de Óleo e Manutenção de Motor.
 - Dados ordenados cronologicamente e preparados para análise temporal.
- Objetivo:
 - Preservar a sequência temporal antes da criação dos modelos.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

df = pd.read_csv("mecanica_dataset.csv", parse_dates=["Data"])
df = df.sort_values("Data").set_index("Data").asfreq("D")

# Tratamento básico para manter a série diária utilizável
df["Trocas_Oleo"] = df["Trocas_Oleo"].interpolate(method="time")
df["Manutencao_Motor"] = df["Manutencao_Motor"].interpolate(method="time")

print(df.head())
print("\nPeríodo:", df.index.min(), "até", df.index.max())
```

[1] ✓ 1.1s

	Trocas_Oleo	Manutencao_Motor
Data		
2024-01-01	11.0	2.0
2024-01-02	9.0	4.0
2024-01-03	12.0	1.0
2024-01-04	15.0	8.0
2024-01-05	25.0	10.0

Período: 2024-01-01 00:00:00 até 2025-12-31 00:00:00

Figura 1: Carregamento, organização e visualização inicial do dataset Mecânica (série temporal diária).

Feature Engineering Temporal

- Atributos criados:
 - Lags (defasagens): 1, 7 e 30 dias
 - Médias móveis: 7 e 30 dias
 - Aplicados às duas séries analisadas
- Cuidados:
 - Uso de shift (1) antes das médias móveis
 - Apenas informações do passado são utilizadas

```
df_features = df.copy()

for coluna in ["Trocas_Oleo", "Manutencao_Motor"]:
    df_features[f"{coluna}_lag_1"] = df_features[coluna].shift(1)
    df_features[f"{coluna}_lag_7"] = df_features[coluna].shift(7)
    df_features[f"{coluna}_lag_30"] = df_features[coluna].shift(30)

    df_features[f"{coluna}_media_7"] = (
        df_features[coluna]
        .shift(1)
        .rolling(window=7)
        .mean()
    )

    df_features[f"{coluna}_media_30"] = (
        df_features[coluna]
        .shift(1)
        .rolling(window=30)
        .mean()
    )

df_features.head(10)
```

✓ 0.0s

Figura 2: Criação de lags e janelas rolantes para as séries temporais.

Validação Temporal e Boas Práticas **unex**

- Validação cruzada:
 - TimeSeriesSplit com 5 folds
 - Treino sempre anterior ao teste
 - Ordem cronológica preservada
- Prevenção de erros:
 - Sem divisão aleatória dos dados
 - `shift(1)` utiliza somente informações anteriores
 - Redução do risco de **Data Leakage**
 - Avaliação em diferentes períodos reduz conclusões dependentes de uma única divisão




Figura 3: Validação temporal cruzada com 5 folds, preservando a ordem cronológica.

Avaliação dos Modelos Baseline

- Modelos avaliados:
 - Naive
 - Média Móvel — 7 dias (MM7)
 - Média Móvel — 30 dias (MM30)
- Métricas:
 - MAE: erro absoluto médio
 - RMSE: penaliza erros maiores
 - MAPE: erro percentual médio




Figura 4: Comparação do MAE médio dos modelos baseline nos 5 folds.

Menores valores indicam menor erro de previsão.

Resultados das Métricas

Principais resultados:

Manutenção de Motor: MM30 → menor MAE e RMSE; Naive → menor MAPE.

Trocas de Óleo: Naive → menor MAE e MAPE; MM7 → menor RMSE.


	Série	Modelo	MAE	RMSE	MAPE (%)
0	Manutenção de Motor	MM30	3.34	4.65	49.20
1	Manutenção de Motor	MM7	3.42	4.75	51.48
2	Manutenção de Motor	Naive	3.60	5.72	46.13
3	Trocas de Óleo	MM30	7.34	8.18	37.52
4	Trocas de Óleo	MM7	7.37	8.11	37.47
5	Trocas de Óleo	Naive	6.62	8.91	32.67

Figura 5: Resumo das métricas de avaliação dos modelos baseline.

Conclusões e Aplicação no Cenário MecâniQA



- **Solução:**
 - Baselines: Naive, MM7 e MM30
 - Lags e janelas rolantes
 - Validação temporal com 5 folds
 - Avaliação por MAE, RMSE e MAPE
- **Aplicação:**
 - Planejamento de estoque de peças
 - Antecipação das variações de demanda
 - Dimensionamento da equipe de mecânicos
- **Resultado:**
 - Desempenho varia conforme série e métrica
 - Baselines estabelecem uma referência para evolução do modelo



Referências



- Materiais da disciplina
 - OAT 2 — Baseline e Métricas de Avaliação
 - Modelo oficial de apresentação — UNEX
 - Barema da Atividade 2 — Baseline e Métricas de Avaliação
- Base de dados
 - MecâniQA Dataset — série temporal utilizada no desenvolvimento